

查恺迪

本科生 · 生成模型与推理加速

清华大学物理系, 北京

☎ (+86) 14790518086 | ✉ ckd23@mails.tsinghua.edu.cn | 🌐 illusionsin30 | 📧 kaidi-zha

“构建能看、能学、能行动的智能系统。”

研究兴趣

生成模型 (Generative Models), 推理加速 (Inference Acceleration)

致力于让大规模生成模型的部署更快、更省：通过量化与混合精度推理、高效架构设计与数据驱动策略，重点关注推理吞吐、显存效率与训练效率。

教育经历

清华大学

中国北京

本科, 数学与物理专业

2023 年 9 月 - 至今 (预计 2027 年毕业)

- 总 GPA: 3.6/4.0, 成绩逐年稳步上升——最近学期 (2026 春) GPA 3.9/4.0。
- 模式识别与机器学习、强化学习与控制、计算机图形学基础三门核心课程均获 A (4.0)。

相关课程

AI 与机器学习	模式识别与机器学习 (A), 强化学习与控制 (A), 计算机图形学基础 (A), 统计机器学习 (B+)
数学	概率论与数理统计 (A), 数学实验 (A), 应用随机过程 (A-), 复变函数 (B+)
计算机	数据结构与算法 (A-), 程序设计基础 (A-), 现代操作系统 (P), 基于 Linux 的 C++ 程序设计 (P)

科研经历

Q-DiT: 面向扩散 Transformer 的精确后训练量化

指导教师: 孟媛教授, 清华大学
计算机科学与技术系

科研助理

2025 年 6 月 - 至今

- 动机:** 统一精度的后训练量化会把宝贵的位宽浪费在不敏感的位置——扩散 Transformer 的量化敏感度在去噪时间步与网络层之间差异巨大, 位宽应分配在损失曲面最陡峭之处。
- 方法:** 参与设计时间步感知、逐层混合精度的 PTQ 框架, 以二阶分析为理论基础: 用去噪损失的 Hessian 迹度量各时间步敏感度, 以 GPTQ (Optimal Brain Surgeon) 误差界定逐层权重扰动代价, 以 Fisher 信息排序各层对训练目标的贡献; 三者结合将位宽分配转化为带约束优化问题, 在全局 W4A4 预算下用动态规划精确求解, 并以交叉调节机制在权重与激活之间再平衡位宽。
- 系统与成果:** 独立将代码库重构为模块化、YAML 驱动的量化-评估流水线 *qdiffusers*, 适配 7 个 DiT 家族模型 (DiT-XL/2、FLUX.2、PixArt- Σ 、OpenSora、Qwen-Image、HunyuanVideo、Wan2.2), 支持多 GPU 并行 GPTQ; 主导 ImageNet-1K 全部实验——W4A4 在 DiT-XL/2 256 $\times$ 256 上取得近无损 FID 7.76, FLUX.2-klein-4B W4A4 FID 25.22 反超 FP16 基线 (26.08)。

ArchEGraph: 几何-拓扑-物理对齐的大规模建筑能耗图数据集

指导教师: 林波荣教授, 清华大学建筑学院; 与 UC Berkeley、MIT 合作

科研助理

2026 年 4 月 - 至今

- 角色:** 论文第二作者, 独立设计并执行全部基准实验; 数据集覆盖 5,481 栋建筑、49,326 个经过验证的模拟案例 (超过 1.33×10^5 个空间节点、 1.44×10^6 个表面节点)。
- 贡献:** 为两类基准任务建立评估协议——从多边形网格重建空间拓扑 (M2G) 与拓扑感知的分区负荷预测; 在跨建筑、跨气候划分下系统评测 7 类模型 (XGBoost、DeepSets、Set Transformer、Perceiver、GATv2、TransformerConv、GraphGPS)。
- 结论:** 实验表明图结构代理模型在分布内能良好学习几何-拓扑-物理耦合, 而跨气候、跨户型泛化仍是关键瓶颈——从实证上验证了该数据集暴露几何漂移与气候漂移的设计目标。

代表性课程项目

TrainYourOwnGPT：从零构建并分析 GPT 风格语言模型

模式识别与机器学习，课程项目

2 人团队；负责 SCALING LAW 与微调实验

2026 春

- 背景：要理解语言模型为何可扩展、架构改动与适配何时真正有效，需要从第一性原理出发的受控实验，而非现成流水线。
- 贡献：从零搭建完整技术栈——在 Penn Treebank 上训练 GPT 风格解码器（RoPE、SwiGLU、pre-norm 残差块），并主导 scaling law 与微调研究（2 人团队）。
- 方案：完成 5 组配置 × 3 个随机种子的超参搜索；在 0.77M–5.46M 参数规模上研究 scaling 行为，并对 QK 归一化、注意力门控、value embedding 做受控消融；以预注册评估指标用 LoRA（0.89% 参数）在 arXiv 摘要上微调 Qwen2.5-0.5B；对比自回归与掩码扩散语言模型（MDLM、LLaDA）并做 A100 吞吐基准测试。
- 成果：最优从零训练模型取得 **105.15 验证集困惑度**；注意力门控是最可靠的架构改进（−2.02 PPL）；LoRA 适配彻底消除考试风格输出（4/15 → 0/15），摘要风格续写提升 8 倍。

fair-SPLIT：兼顾精度、稀疏性与公平性的近最优决策树

统计机器学习，课程项目

2 人团队；负责 SPLIT 系列方法实现与实验设计

2026 春

- 动机：贪心决策树（CART）划分短视且无公平性保证，而仅删除敏感属性并不能消除间接歧视——我们研究“近最优树 + 轻量后处理”能在多大程度上弥合这一差距。
- 方法与实验：实现 SPLIT 系列算法，以动态规划前瞻可证明地最优求解最具判别力的顶层划分、再以贪心补全；在 **12 个公开数据集**（6 个含敏感属性）× 5 个随机种子上与 CART 对比，测量精度、训练时间与 SPD/DI/EOD 公平性指标——SPLIT 在 COMPAS、HELOC、Heart、Law School 上取得更优精度。
- 公平性：提出叶节点级 Pareto 公平重校准方法 LPFR（可部署的后处理方案）；标签感知校准将 Adult 数据集的人口统计平等差距从 0.17 降至 **0.003**。代码开源：github.com/illusionsin30/fair-SPLIT。

AIDER：抑制离策略强化学习中的偶然不确定性冲击

强化学习与控制，课程项目

8 人团队；负责扩散/流模型多模态策略方向

2026 春

- 背景：离策略强化学习会因内在估计噪声产生瞬时的价值高估冲击（aleatoric impulse）；现有的启发式退火方案对超参数敏感且渐近不一致。
- 贡献：团队提出 EMA 锚定的证据回归算子 DEAR，端到端学习高阶偶然不确定性，并构建 AIDER 机制将其转化为悲观目标与探索奖励、彻底摆脱退火调度；我负责探索该框架向扩散/归一化流多模态策略的扩展。
- 方案：以高阶 EMA 目标网络作为经验锚点，通过高斯 NLL 目标让每个 critic 经由证据计数参数化直接估计自身目标值方差；总价值不确定性（集成认知 + 学习所得偶然）同时驱动下置信界 critic 目标与上置信界行为策略。
- 成果：在 DeepMind Control Suite 上取得 7 个 model-free 基线中的最佳平均表现（Humanoid-run 回报较前作 575 → 648）；部署于四驱车辆纵向速度跟踪任务，RMSE **0.349 m/s**（约 1.5% 误差）。

CPU 路径追踪器：C++ 物理渲染器

计算机图形学基础，课程项目

个人项目

2026 春

- 背景：基于物理的渲染本质上是渲染方程的蒙特卡洛估计——朴素采样收敛缓慢，方差缩减与加速结构才是实用化的关键。
- 贡献：独立用 C++ 从零构建完整 CPU 渲染器，贯通 Whitted 光线追踪与蒙特卡洛路径追踪。
- 方案：直接光采样（NEE）、带 Schlick Fresnel 的 Cook-Torrance glossy BRDF、Russian Roulette 路径终止、BVH 加速结构与景深；设计确定性逐像素种子与无锁行调度实现多线程。
- 成果：**64 线程加速 49 倍**且输出与串行渲染逐字节一致；每项效果均通过受控消融渲染验证（NEE 开关、Fresnel、粗糙度扫描、全反射）。

专业技能

编程语言

Python, C/C++, CUDA, $\LaTeX$

深度学习

PyTorch, JAX, HuggingFace Transformers & Diffusers, PEFT/LoRA, 量化工具链

工具

Git, Linux, Docker, 多 GPU 训练, OpenMP / `std::thread`

语言

中文（母语），英语（CET-4: 596, CET-6: 534）