

个人陈述

查恺迪 ckd23@mails.tsinghua.edu.cn

“Fundamental drivers—compute, data quality and breadth, objective functions—still determine progress in AI.” —Dario Amodei, Anthropic CEO

在复现GPT-2时，我第一次真切地感受到规模扩展的代价：显存溢出迫使我将批量大小压缩到极限，训练指标的周期性爆炸让我不得不反复回溯梯度流的每一个环节。调试的过程让我意识到，Scaling Law描述的是模型与数据协同增长的理想图景，却对随之而来的资源调度危机与数据质量陷阱保持沉默。计算资源如何被高效利用，训练数据如何被精准筛选——这两个问题在那段时间里反复困扰着我，也最终成为我选择系统研究的原点。

我是清华大学物理系数理基础科学专业的查恺迪。跨越数学、物理与计算机科学三个领域的训练塑造了我看问题的习惯：我倾向于追问现象背后的数学本质。当我意识到深度学习的核心是统计意义下的优化问题时，数据分布与计算代价之间的关系让我认识到模型的性能上限不只由参数量决定，更由数据质量与计算资源的利用效率共同决定。

个人情况概述

在本科学习期间，我修读应用随机过程、概率论与数理统计、数值分析、数学物理方程、复分析和量子力学等数学、物理专业课程，并取得较为优异的成绩。这些课程夯实我的数理基础，也培养我处理复杂系统与高维数据的能力。不局限在传统理学课程之中，我也积极接触计算机领域的课程，跟进信息化时代的步伐。在计算机科学方面，我修读数据结构与算法、模式识别与机器学习、统计机器学习、强化学习与控制论、计算机图形学等课程，在学习过程中建立起完备的计算机编程与算法、机器学习与深度学习的知识框架。在一次次实践中，我熟练掌握Python、C/C++，并能灵活运用PyTorch、Jax等深度学习框架，熟悉Git、Linux、Docker等

开发工具。我坚信，构建真正智能的系统不仅需要参数量巨大的模型和海量数据，更需要巧妙的架构设计和针对性的数据利用策略。

为了让模型在后端部署中实现快速推理，我在计算机系孟媛老师指导下参与DiT的后训练量化研究。我以语言模型中广泛应用的GPTQ为基础，推导量化误差与二阶Hessian矩阵的关系，并在此基础上提出一种层间混合精度方案：敏感层保留更高位宽，冗余层激进压缩，在整体位宽预算不变的前提下最小化量化损失。在ImageNet-1K的评估中，W4A4方案下Inception Score降幅不超过5%，FID与sFID增幅不超过15%，显著优于SmoothQuant、PTQ4DiT等均匀量化方案。这段经历让我深入理解推理效率的提升与精度保持之间的权衡，本质上是一个在离散约束下的优化问题，而现有方法对层间异质性的处理仍然粗糙，需要进一步的改进。

在与建筑系同学合作的ArchEGraph图数据集项目中，我负责实验与评估模块：在GNN与Transformer等不同架构下设计基准测试，系统分析超参数变化对模型在建筑图结构任务上的泛化性能的影响。这一经历让我认识到，数据集的质量不是静态属性，而是在模型与数据的持续交互中被揭示和修正的。评估本身就是数据构建的一部分。

博士期间研究规划

我计划在博士阶段围绕计算效率与数据质量的协同优化这一核心问题展开研究，聚焦于面向硬件拓扑的模型架构设计与训练数据的价值量化与主动筛选两个相互关联的方向。

在DiT量化研究中，我观察到大量时间消耗在CPU与GPU之间的数据搬运上，而非实际计算。这促使我思考：如果模型架构的设计能够从一开始就考虑内存访问模式与计算单元的关系，而不是将硬件适配作为事后的压缩步骤，会带来什么？我希望研究如何在架构设计阶段将内存带宽、计算并行度等硬件约束显式地纳入优化目标，使训练与推理的吞吐量从根本上提升。

“数据质量”是一个被频繁提及却很少被精确定义的概念。在ArchEGraph项目中，我注意到不同子集对模型泛化能力的贡献差异悬殊，但缺乏系统性的理论解释。我希望建立一套数据价值评估框架，将对齐质量、信息互补性、分布覆盖多样性等维度统一到可优化的目标函数中，指导主动学习与课程学习策略的设计。

这两个方向并非独立：高效的硬件感知架构能够在固定计算预算内处理更多数据，而高质量的数据筛选能够降低模型收敛所需的计算量。我希望探索两者协同设计的可能性，并将研究成果发表于ICML、NeurIPS等顶会。从更长远的视角来看，我希望这套方法论能够帮助AI系统在资源受限的真实部署场景中真正落地。我期待在博士训练过程中，不仅成为一名优秀的研究者，更成为一个能够独立提出并解决重要问题的学者。